

Real-time Speech Enhancement System Hybrid ESP32-S3 and High-Performance Server Architecture

Dang Xuan Lam
PTIT HCM

Ngày 12 tháng 3 năm 2026

Tóm tắt nội dung

Đồ án này trình bày thiết kế, phân tích và triển khai một hệ thống khử nhiễu tiếng nói (Speech Enhancement) toàn dải (48 kHz) theo thời gian thực, dựa trên kiến trúc nơ-ron hồi quy kết hợp xử lý tín hiệu số (Hybrid DSP/Deep Learning) lấy cảm hứng từ mô hình RNNNoise. Mục tiêu trọng tâm là hiện thực hóa thuật toán trên vi điều khiển nhúng ESP32-S3, đồng thời đánh giá chi tiết các rào cản vi kiến trúc (micro-architecture) của phần cứng. Thông qua việc phân tích phổ và mô phỏng thính giác Bark, mô hình AI dự đoán các hệ số khuếch đại (gain) lý tưởng, kết hợp cùng bộ lọc lược (comb filter) để bảo toàn cấu trúc hài âm. Bằng các kỹ thuật tối ưu hóa mức hệ thống như sử dụng tập lệnh SIMD PIE (Processor Instruction Extensions), định tuyến bộ nhớ IRAM cho các nhân tính toán và lượng tử hóa, độ trễ cấu phần DSP đã giảm đáng kể (lên đến 3.64 lần). Dù vậy, nghiên cứu chỉ ra rằng băng thông bộ nhớ PSRAM và hiện tượng Cache Thrashing trên bộ đệm L1 (32KB) cấu thành nút thắt cổ chai vật lý không thể vượt qua đối với mạng suy luận kích thước 1.3MB khi yêu cầu độ trễ dưới 10ms. Để khắc phục, một kiến trúc lai phân tán (Edge-to-Server) được đề xuất, trong đó ESP32-S3 đóng vai trò *Audio Gateway* đa nhân, chuyển giao luồng dữ liệu cho máy chủ biên dịch bằng AVX2, giúp giảm tổng độ trễ suy luận xuống dưới 0.1ms và duy trì chất lượng thoại xuất sắc.

Mục lục

1	Giới thiệu	3
2	Kiến trúc Hệ thống (Hybrid DSP/Deep Learning)	4
2.1	Giai đoạn 1: Tiền xử lý và Trích xuất Đặc trưng (Pre-processing & Feature Extraction)	4
2.2	Giai đoạn 2: Suy luận Học sâu (RNN Inference & Noise Spectral Estimation) . .	5
2.3	Giai đoạn 3: Hậu xử lý và Khôi phục Tín hiệu (DSP Synthesis)	7
3	Quá trình Huấn luyện Mô hình AI (Training Pipeline)	8
3.1	Chuẩn bị Dữ liệu và Đặc trưng hóa (Features Extraction)	8
3.2	Tối ưu hóa Hàm Mất mát (Custom Perceptual Loss)	8
3.3	Cắt gọt nơ-ron: Thừa thớt hóa (Sparsification)	8
3.4	Ép xung và Dịch thuật (Quantization & C-Header Export)	9
4	Thực nghiệm và Đánh giá	10
4.1	Phân tích Giới hạn Bộ nhớ (Hardware Bottleneck Analysis)	10
4.2	Mô hình Kiến trúc Phân tán (Edge-to-Server)	10
4.3	Hàm Mất mát & Lược bỏ Tham số (Training & Sparsification)	11
5	Kết luận và Hướng phát triển	12

1 Giới thiệu

Hệ thống khử nhiễu tiếng nói đơn kênh (Single-channel Speech Enhancement) luôn là một bài toán kinh điển nhưng đầy thách thức trong lĩnh vực xử lý tín hiệu. Mặc dù các kỹ thuật truyền thống như trừ phổ (spectral subtraction) [1] hay lọc hậu kỳ (post-filtering) [2] đã được ứng dụng rộng rãi, chúng thường để lại những vết nhiễu cơ học (musical noise) do suy giảm năng lượng không đồng đều giữa các dải tần. Sự bùng nổ của Deep Learning mở ra cơ hội giải quyết bài toán này với độ phân giải cao hơn. Tuy nhiên, các kiến trúc mô hình học sâu truyền thống thường yêu cầu mô hình hóa hàng ngàn điểm tần số đồ sộ, dẫn đến khối lượng tính toán "khổng lồ", không phù hợp với các hệ thống nhúng với ràng buộc thời gian thực (real-time constraints) [3].

Khác với cách tiếp cận End-to-End, mô hình RNNoise nguyên bản của J.-M. Valin [3] giải quyết rào cản tính toán bằng cách kết hợp sức mạnh phân loại của Deep Learning với độ tinh giản của xử lý tín hiệu số (DSP). Thay vì tái tạo lại toàn bộ dạng sóng âm, hệ thống học sâu chỉ tập trung dự báo các hệ số khuếch đại (ideals gains) trên các dải băng tần thính giác (Bark scale), nhường phần tinh chỉnh tín hiệu giữa các hài âm (harmonics) cho hệ thống lọc lược truyền thống (pitch comb filtering). Mô hình thực tế triển khai trong báo cáo này đã được nâng cấp với 32 dải Bark (thay vì 22 như [3]) và đưa thêm các khối chập (1D-CNN) nhằm nâng cao sức mạnh nhận diện trên không gian [4].

Dù mô hình này đã rất tinh gọn gọn nhẹ (1.3 triệu tham số dạng INT8 đối với cấu hình thực tế), việc triển khai suy luận với tốc độ 10ms/frame (đối với mẫu 48kHz) trên phần cứng ESP32-S3 đặt ra giới hạn nghiêm ngặt không chỉ về số phép toán dấu phẩy động (FLOP/s) mà còn về cường độ I/O của bộ nhớ (Memory Bandwidth).

Bài báo cáo này được cấu trúc lại như sau: Phần 2 mô tả tường minh luồng tín hiệu lai và mô hình học sâu. Phần 3 tập trung phân tích các phương pháp tối ưu hóa cực đoan (SIMD PIE, IRAM, Quantization) đối với ESP32-S3, đồng thời chỉ ra rào cản vật lý của bộ đệm (PSRAM Bottleneck). Phần 4 đề xuất thiết kế kiến trúc phân tán Edge-to-Server để triệt tiêu giới hạn phần cứng, và Phần 5 kết luận lại ưu, nhược điểm của giải pháp đạt được, đi từ phần cứng nhúng đến vi kiến trúc cấp hệ thống.

2 Kiến trúc Hệ thống (Hybrid DSP/Deep Learning)

Khác với các phương pháp học sâu toàn trình (End-to-End Deep Learning) thường đòi hỏi năng lực tính toán lớn để trực tiếp tái tạo dạng sóng (waveform) hay phổ tín hiệu (spectrogram), kiến trúc RNNoise [3] giải quyết rào cản tính toán thời gian thực bằng triết lý thiết kế lai (hybrid). Hệ thống sử dụng các thuật toán Xử lý Tín hiệu Số (DSP) để trích xuất đặc trưng và hậu xử lý tín hiệu, đồng thời sử dụng mạng học sâu (Deep Learning) để ước lượng các tham số triết nhiễu. Cách tiếp cận này giúp giảm đáng kể số lượng tham số mô hình, tạo tiền đề để triển khai trên các thiết bị nhúng có tài nguyên hạn chế.

Quá trình xử lý tín hiệu được chia thành 3 giai đoạn chính, thể hiện sự kết hợp chặt chẽ giữa DSP và Deep Learning.


2.1 Giai đoạn 1: Tiền xử lý và Trích xuất Đặc trưng (Pre-processing & Feature Extraction)

Tín hiệu âm thanh đầu vào trên miền thời gian có tần số lấy mẫu $f_s = 48$ kHz trước tiên được đi qua một Cửa lọc Thông cao (High-pass Filter) IIR nhằm triệt tiêu các thành phần nhiễu điện từ tần số cực thấp (DC offset, tiếng ồn gió cấp). Sau đó, luồng tín hiệu được phân chia thành hai nhánh xử lý song song:

1. **Cửa sổ hóa chồng lấn và Biến đổi FFT (Overlapped Window & FFT):** Tín hiệu được cắt rã thành các khung (frames) có kích thước 480 mẫu (tương đương 10 ms). Để giảm thiểu rò rỉ phổ năng lượng tại biên, hệ thống áp dụng hàm cửa sổ Vorbis có kích thước gấp đôi 960 mẫu (20 ms) với độ chồng chéo 50% (overlap). Khung tín hiệu này sau đó trải qua nòng cốt biến đổi nhanh KissFFT 960 điểm, sinh ra 481 điểm phổ tần số (không gian phức).
2. **Phân tích Cao độ (Pitch Analysis):** Cùng lúc, nhánh thứ hai thực hiện thuật toán Tương quan chéo (Cross-correlation) dò quét trên miền thời gian nhằm khoanh vùng chu kỳ cơ bản (pitch period). Các ngưỡng chặn quét được giới hạn chặt chẽ ở độ trễ (lag) từ *60 mẫu* (tương đương cao độ tối đa 800 Hz) đến *768 mẫu* (tương đương cao độ tối thiểu 62.5 Hz). Tại đây, một biến đổi FFT phụ trợ tiếp tục giải mã cửa sổ cao độ này thành phổ tương quan.

Giao hội từ nguồn phổ FFT 481 điểm nhánh một và phổ chu kỳ Pitch nhánh hai, hệ thống khởi động khối **Trích xuất Đặc trưng (Feature Extraction)**. Ở khâu này, bộ phân tích dải Bark (Bark-scale Banding) chắt lọc các điểm tần số rải rác nguyên gốc, gom nhóm phi tuyến thành 32 dải băng thông năng lượng.

Kết quả chung cuộc của Giai đoạn 1 xuất ra vector đặc trưng trọn vẹn 65 chiều (32 hệ số năng lượng phổ dải cung cấp cho quy trình mạng học sâu nội ứng).




Hình 1: Sơ đồ khối tổng thể của quá trình xử lý tín hiệu lai DSP/AI với bộ đệm Trễ (Delay) theo mã nguồn thực tế.

2.2 Giai đoạn 2: Suy luận Học sâu (RNN Inference & Noise Spectral Estimation)

Thay vì sử dụng kiến trúc rẽ nhánh phân kỳ nhỏ (khoảng 85 nghìn tham số) như đề xuất sơ khởi năm 2018 [3], hệ thống thực tế áp dụng mô hình kiến trúc xếp chồng (Stacked) nâng cấp (2024) quy mô lớn với dung lượng lên tới xấp xỉ 1.34 triệu tham số (chính xác: **1,341,729 weights**). Mạng học sâu tiếp nhận vector 65 chiều và thực hiện biểu diễn lại phổ đặc trưng thông qua 3 lớp phân giải:


1. **Trích xuất Đặc trưng cục bộ (Conv1D)**: Đầu vào đi qua 2 lớp Tích chập 1 chiều (1D Convolution) với nhân chập (kernel size) bằng 3 nhằm khám phá các mối liên hệ không gian/tần số ngắn hạn của tín hiệu.
2. **Nhớ chuỗi thời gian (Stacked GRU)**: Dữ liệu lan truyền qua 3 lớp *Gated Recurrent Unit (GRU)* xếp chồng liên tiếp. Mỗi lớp sở hữu kích thước ma trận ẩn cực đại lên tới 256 nơ-ron, giúp mô hình hóa triệt để không gian chuỗi thời gian của tiếng ồn ổn định lẫn nhiễu biến đổi (non-stationary noise).
3. **Kết nối tắt rẽ nhánh (Skip Connections)**: Thay vì chỉ lấy hệ số từ lớp cuối, hệ thống thực hiện nối gộp (Concatenation) trực tiếp các ma trận $\rightarrow$ (Đầu ra lớp Conv1D thứ 2 + GRU1 + GRU2 + GRU3). Khái niệm rẽ nhánh DenseNet này giúp bảo toàn gradient đi sâu và nâng cao độ hội tụ của bộ trọng số.



Hình 2: Cấu trúc Topology mạng GRU 256-unit (bản cải tiến 2024) áp dụng kỹ thuật nối gộp Skip-Connections.

Từ ma trận được nối gộp, khối Mạng Nơ-ron xuất ra hai cụm quyết định độc lập thông qua hai lớp kết nối dày đặc (Dense Layers):

- **Phát hiện Hoạt động Giọng nói (Voice Activity Detection - VAD):** Cờ nhị phân mềm (soft-flag) đầu ra $\in [0, 1]$ quyết định thời điểm hệ thống cần cập nhật mức định lượng phổ ồn (when to adapt).
- **Hệ số Trừ Phổ (Spectral Subtraction Gains):** 32 hệ số khuếch đại (Gains) $\hat{g}_b \in [0, 1]$ ước lượng tuyệt đối khối lượng năng lượng tạp âm cần trừ bỏ (what to subtract). Giới hạn ở ngưỡng 32 tham số trực tiếp ngăn chặn các sai nhiễu do mạng (artifacts) trong bước trừ phổ tiếp theo.




Hình 3: Nguyên lý tương tác giữa VAD, Ước lượng Phổ ồn và Trừ phổ (Spectral Subtraction) trực tiếp thông qua dải Bark Gains.

2.3 Giai đoạn 3: Hậu xử lý và Khôi phục Tín hiệu (DSP Synthesis)

Nhận lại bằng thông 32 hệ số *Gains* xuất chuẩn từ mô hình AI cùng dữ kiện tần số từ Giai đoạn 1, thuật toán DSP khép kín quy trình tổng hợp dựa trên đồ thị tái tạo:

- **Nội suy Hệ số khuếch đại (Band Gain Interpolation):** Các hệ số Gain đại diện cho độ suy hao 32 dải Bark được nội suy tuyến tính trở lại thành một tập hợp đường cong suy giảm liên tục, khớp hoàn hảo với bình độ phân giải của phổ FFT gốc nhằm ngăn chặn đứt gãy năng lượng phổ.
- **Lọc Cao độ (Pitch Filtering):** Song hành với đường truyền Nội suy, phổ FFT thô ban đầu được áp dụng hệ thống Lọc cao độ. Căn cứ vào dữ liệu chu kỳ *Pitch* được trích xuất từ trước, màng lọc này gạt bỏ triệt để phần năng lượng nhiễu lọt thỏm giữa các khe họa âm (inter-harmonic noise) của tiếng nói.
- **Nhân hệ số mặt nạ (Multiplier X) và Biến đổi nghịch nghịch (IFFT):** Phổ tín hiệu đã qua màng lọc Pitch sẽ được nhân vì xử lý tích trực diện (X) với mốc hệ số suy hao vừa được nội suy. Sau khi kết tủa phổ làm sạch, dòng biến đổi Fourier Nhanh Nghịch đảo (IFFT) ép tín hiệu chuyển ngược từ miền tần số quay trở về miền thời gian đại số.
- **Cộng chồng lấn Cửa sổ (Window Overlap-add):** Điểm cuối cùng của quy mô là khi các khung tín hiệu thời gian được triệt xuất liên mạch qua thuật toán cộng chồng lấn (overlap-add), giải phóng hoàn chỉnh khối sóng âm rành mạch, bảo tồn thanh âm con người nguyên bản.



Hình 4: Sơ đồ luồng Giai đoạn 3: Hậu xử lý tín hiệu (DSP Synthesis) gồm Nội suy Gains, Lọc lược Cao độ và IFFT chồng lấn.

3 Quá trình Huấn luyện Mô hình AI (Training Pipeline)

Thuật toán cấu trúc mạng AI RNNoise dù được thiết kế mỏng nhẹ, nhưng để đạt được chất lượng lọc nhiễu "Human-like" (giống thính giác người), hệ thống đòi hỏi một quy trình huấn luyện (Training Pipeline) cực kỳ đồ sộ và tinh vi. Trong khuôn khổ đề án, hệ thống học sâu đã được tái thiết kế và huấn luyện hoàn toàn bằng nền tảng **PyTorch** thay cho Keras bản gốc, giúp dễ dàng tích hợp lượng tử hóa (Quantization) và thưa thớt hóa (Sparsification).

Quy trình huấn luyện này chạy độc lập dưới dạng Offline, được chia thành bốn bước trọng tâm:

3.1 Chuẩn bị Dữ liệu và Đặc trưng hóa (Features Extraction)

Thay vì nạp trực tiếp hàng triệu tệp âm thanh WAV dung lượng khổng lồ vào GPU, nền tảng sử dụng một công cụ trích xuất được viết bằng C (tool `dump_features.c`). Công cụ này đóng vai trò ép xung dữ liệu thô:

- **Định dạng âm thanh:** Mọi tệp âm thanh (cả tiếng nói sạch *Clean Speech* và tạp âm *Noise*) đều được chuẩn hóa về định dạng Raw PCM 16-bit, tần số lấy mẫu 48kHz (qua phần mềm cục bộ SoX).
- **Ghép nhiễu động (Dynamic Mixing):** Quá trình gộp âm thanh được thực hiện ngay tại thời gian chạy (runtime). Công cụ quét ngẫu nhiên mức tỉ số Tín hiệu trên Nhiễu (SNR) và ngẫu nhiên cộng ghép tiếng ồn định hướng vào tiếng nói sạch.
- **Trích xuất Vector 65 chiều:** Áp dụng chính xác chuỗi mạng DSP ở Giai đoạn Tiền xử lý (FFT $\rightarrow$ Phân dải Bark $\rightarrow$ Tính Năng lượng & Cao độ) để biến đổi các khung tín hiệu nhiễu thành các Vector Đặc trưng 65 chiều. Đồ thị đầu ra (Ground-truth) chính là mức chênh lệch Năng lượng Lý tưởng (Ideal Ratio Mask), lưu thành luồng ma trận số thực `.f32`.

3.2 Tối ưu hóa Hàm Mất mát (Custom Perceptual Loss)

Dữ liệu Đặc trưng `.f32` sau đó được đẩy vào mô hình 3 lớp GRU 256 nơ-ron trên môi trường PyTorch. Khác với các mô hình phân loại thông thường sử dụng Cross-Entropy/MSE tĩnh, RNNoise tính toán sai số thông qua *Hàm mất mát Cảm quan thính giác (Perceptual Loss)*:

$$Loss = Loss_{gain} + \lambda \cdot Loss_{vad} \quad (1)$$

Trong đó:

- $Loss_{gain} = \frac{1}{N} \sum (1 + 5 \cdot VAD) \cdot Mask(g) \cdot (\hat{g}^\gamma - g_{target}^\gamma)^2$: Hệ thống trừng phạt cực nặng đối với các lỗi suy hao Gain tại những dải Bark đang có tiếng nói ($5 \cdot VAD$). Biến số gamma γ được thiết lập nhằm mô phỏng độ cong cảm nhận âm lượng phi tuyến của tai người.
- $Loss_{vad}$ là hàm Cross-Entropy nhị phân thông thường, đóng vai trò phạt những dự đoán sai lệch về xác suất có tiếng người (Voice Activity).

Mô hình sử dụng thuật toán tối ưu **AdamW** ($lr = 1e^{-3}$, $\beta = [0.8, 0.98]$) kết hợp Lịch trình giảm tốc (Lambda LR Scheduler) xuyên suốt khoảng 150 vòng hội tụ (Epochs).

3.3 Cắt gọt nơ-ron: Thưa thớt hóa (Sparsification)

Mặc dù 3 lớp GRU 256 nơ-ron mang lại hiệu năng cao, lượng tham số 1.3×10^6 vẫn là rào cản quá lớn về băng thông và tốc độ chép xung đối với Cache L1 của đa số các hệ gen CPU.

Tại bước huấn luyện, hệ thống áp dụng kỹ thuật **Thừa thớt hóa ma trận trọng số (Sparsification/Pruning)**. Trong quá trình Backpropagation (Lan truyền ngược), các trọng số nội tại (weights) bên trong khối GRU gần tiệm cận 0 sẽ bị ép buộc rụng hẳn (gán bằng 0). Kết thúc dải huấn luyện, mô hình rơi rụng các cầu nối nơ-ron thừa thãi, tỷ lệ thừa thớt có thể đạt từ **20% đến 30%**. Mạng lúc này đã trở nên "xốp" hơn, tạo tiền đề để các nhân thư viện SIMD CPU tính toán bỏ qua các chỉ số tham số dư thừa, tăng tốc trực tiếp thời gian suy luận.

3.4 Ép xung và Dịch thuật (Quantization & C-Header Export)

Mô hình sau khi hội tụ sẽ mang các tệp trọng số có cấu trúc dấu phẩy động 32-bit (FP32 .pth). Để tương thích với đồ án nhúng và hạ tầng Shared Library (C/C++), một kịch bản `export_to_c.py` được kích hoạt với nhiệm vụ:

- Xê lùì dấu phẩy tình **Lượng tử hóa lượng giác (8-bit Quantization)**: Đại bộ phận các trọng số GRU được ép xung từ tỷ lệ float32 về int8 ($\sim 1/128$ scale). Điều này giúp kích thước model giảm thẳng 4 lần.
- Xuất mã nguồn: Biến đổi lưới tensor nơ-ron thành một file Header ngôn ngữ C (`rnn_data.c`, `rnn_data.h`), chứa các mảng 1D cấu trúc tình.

Tại đây, quá trình Huấn luyện Mô hình khép lại. Hệ thống mạng thần kinh nhân tạo chính thức hóa đá thành các mã ASCII tình, sẵn sàng được nạp (load) thẳng vào RAM nhúng/Server qua Giai đoạn Suy luận Real-time.

4 Thực nghiệm và Đánh giá

Mặc dù mô hình RNNoise hướng tới tính tinh gọn trong kiến trúc thuật toán, khối lượng hơn 1.34 triệu tham số (1,341,729 weights) của mô hình ứng dụng toàn thời (Standalone Edge AI) trên vi điều khiển ESP32-S3 vẫn đối mặt với những giới hạn phần cứng đặc thù về cấu trúc bộ nhớ.

4.1 Phân tích Giới hạn Bộ nhớ (Hardware Bottleneck Analysis)


Kết quả thực nghiệm cho thấy năng lực tính toán (Compute-Bound) của vi điều khiển ESP32-S3 có thể đáp ứng được các tác vụ DSP cơ bản thông qua khả năng tối ưu hóa tập lệnh vi mô. Bằng việc áp dụng tập lệnh SIMD PIE (Processor Instruction Extensions) trên Internal RAM, thời gian thực thi của tác vụ trích xuất đặc trưng (*Pitch Search*) đã được tối ưu hóa tăng cường tốc độ lên **3.64 lần**.

Tuy nhiên, quá trình suy luận mạng học sâu (AI Inference) đã để lộ rào cản nghiêm trọng đối với thiết kế vi kiến trúc của phần cứng. Đặc thù của mạng tuần tự hồi quy (RNN) yêu cầu hệ thống nạp lại toàn bộ trạng thái trọng số tại mỗi bước khung (step), nên không phản ánh tính chất tái sử dụng cục bộ (No Weight Reuse). Do bộ nhớ đệm L1 (L1 Cache) của ESP32-S3 chỉ giới hạn ở mức 32KB, CPU liên tục phải truy xuất và thay thế dữ liệu từ bộ nhớ ngoài PSRAM thông qua chuẩn giao tiếp Octal SPI. Quá trình này dẫn đến hiện tượng trễ thu hồi (Cache Thrashing), khi mà băng thông PSRAM duy trì ở giới hạn ~ 130 MB/s. Số liệu đo đạc chỉ ra rằng thời gian xử lý suy luận mạng RNN trên thiết bị tiêu tốn khoảng **99 ms** trên mỗi khung 10ms. Khoảng chênh lệch này vi phạm nghiêm ngặt yêu cầu thời gian thực của ứng dụng xử lý âm thanh số, vốn dĩ yêu cầu trễ xử lý (processing delay) phải thấp hơn độ dịch khung (frame shift). Kết quả này định hình cần thiết đổi cấu trúc quy hoạch tính toán xử lý đối với phương thức thiết kế nhúng.

4.2 Mô hình Kiến trúc Phân tán (Edge-to-Server)

Nhằm vượt qua nút thắt băng thông (I/O Bottleneck), chúng tôi đề xuất kiến trúc xử lý lai phân tán kết hợp Thiết bị biên và Máy chủ (Edge-to-Server):

1. **Thiết bị biên (ESP32-S3 Gateway):** Chỉ chuyên trách nhiệm vụ thu nhận, lấy mẫu ADC, và giải mã ngắt I2S DMA bằng lõi xử lý Core 1. Lõi Core 0 đảm nhận việc đóng gói luồng bit âm thanh PCM chuẩn hóa để truyền phát theo giao thức mạng UDP. Việc giảm tải suy luận tính toán làm cho độ trễ nội sinh tại khâu thu phát đạt tiệm cận ≈ 10 ms.
2. **Máy chủ Suy luận (AI Inference Server):** Đảm nhận trọn bộ công tác tính toán Mạng nơ-ron và DSP. Với lợi thế lớn về bộ nhớ RAM DDR5 băng thông rộng và tập lệnh đa phần tử AVX2, máy chủ hoàn tất tính toán suy luận 1.34 triệu tham số chỉ duy trì ở mức < 0.1 ms.



Hình 5: Sơ đồ luồng dữ liệu Kiến trúc Phân tán lai (Edge-to-Server Hybrid) giữa thiết bị gốc ESP32-S3 Đa nhân và Máy chủ AI qua giao thức đường truyền UDP.

Với kiến trúc giải tỏa này, thời gian luân chuyển toàn trình (End-to-End Latency) bao gồm: Tiền trình Lấy mẫu I2S (≈ 10 ms) + Độ trễ mạng nội bộ LAN (≈ 20 ms) + Thời gian suy luận Inference (< 0.1 ms). Tổng trễ hệ thống cấu thành $\approx \mathbf{30.25ms}$, đáp ứng tiêu chuẩn xử lý âm thanh thời gian thực cho hạ tầng truyền thông viễn thông (< 40 ms).

4.3 Hàm Mất mát & Lược bỏ Tham số (Training & Sparsification)

Giới hạn khả năng phần cứng buộc hệ thống đào tạo (Training) mô hình qua cơ sở dữ liệu (PyTorch) phải tối ưu bộ trọng số mạnh mẽ. Kho văn bản dữ liệu hỗn hợp thu thập từ tập dữ liệu DNS Challenge, FOSD và VIVOS được huấn luyện thông qua hàm mất mát đánh giá mức suy giảm nhận thức Perceptual Loss ($\gamma = 0.25$):

$$\mathcal{L}_{gain} = \frac{1}{N} \sum (1 + 5 \cdot \text{VAD}) \cdot \text{Mask} \cdot (\hat{g}^{0.25} - g_{ideal}^{0.25})^2 \quad (2)$$

Hàm tổ hợp tổn thất trên kết hợp đánh trọng số chặt đối với nhân hoạt động âm thoại (Voice Activity Detection - VAD) nhằm hạn chế sinh tín hiệu ảo tại các dải không có tiếng người. Hơn thế nữa, quá trình rút gọn quy mô, kỹ thuật Thừa hóa mô hình Cấp tiến (*Progressive Sparsification*) được ban hành, ép ràng buộc ma trận tính toán GRU quy nạp trên khối kích thước 8×4 . Chiến lược huấn luyện đánh rơi này triệt tiêu xấp xỉ 70% chỉ số lượng tham số kết nối (đưa ma trận ẩn về giá trị 0), góp phần đẩy nhanh tốc độ hội tụ và giảm độ ngốn bộ đệm mà không làm giảm phẩm chất khôi phục hài âm thoại gốc.

5 Kết luận và Hướng phát triển

Đồ án đã trình bày quy trình khảo cứu, phân tích và triển khai kiến trúc học sâu lai DSP/RNN (RNNoise) trong bài toán khử nhiễu tiếng nói đơn kênh. Thông qua việc phân bổ tài nguyên có hệ thống từ cấp độ vi kiến trúc phần cứng (tập lệnh SIMD PIE, phân bổ Internal RAM, lượng tử hóa INT8) trên phần cứng nhúng tiêu chuẩn công nghiệp ESP32-S3, chúng tôi đã đẩy lùi hoàn toàn những cản trở về giới hạn tính toán vô hướng (Compute Bound). Tuy nhiên, các phân tích thực nghiệm xuyên suốt đồ án cũng chứng minh một cách xác đáng về nút thắt cổ chai không thể tránh khỏi đối với hệ thống bộ nhớ vi điều khiển (Memory/IO Bound). Khác với các thuật toán CV (Computer Vision), trọng số của Recurrent Neural Networks không mang tính tái sử dụng cục bộ (no weight reuse), do đó giới hạn cứng về băng thông PSRAM triệt tiêu độ khả thi của suy luận thời gian thực đối với bất kỳ mô hình hồi quy lớn (~ 1.3 MB) dựa trên khung 10ms.

Giải pháp *Kiến trúc Phân tán Edge-to-Server* được đề xuất là một thỏa hiệp hoàn hảo giữa tính di động thiết bị biên (quản lý DMA, lấy mẫu, truyền phát) và sức mạnh xử lý AVX2 của máy chủ. Cấu trúc hybrid này đã đem lại trải nghiệm âm thanh sắc nét, sạch tạp âm với độ trễ tối thiểu, triệt tiêu sự vấp vấp vốn dĩ trên các hệ mã hóa băng tần tiêu biểu.

Hướng phát triển trong tương lai

Để có thể đóng gói hoàn toàn thuật toán học sâu vào thiết bị biên siêu nhỏ (Standalone Edge AI), tương lai nghiên cứu có thể định hướng theo hai chiến lược cơ bản:

1. **Thưa hóa mô hình (Sparsification):** Khai thác bản chất phân bố rời rạc của các điểm sáng ma trận trọng số trong mạng RNN để bỏ qua phần lớn các phép tính vô giá trị (bằng 0). Điều này có thể kéo giảm quy mô lưu trữ từ 1.3 MB xuống dưới 100 KB, vừa vận với dung lượng L1 Cache nhỏ nhoi của vi điều khiển.
2. **Lượng tử hóa cấp tính (Sub-byte Quantization):** Thay vì tính toán dựa trên mức INT8, chuyển sang mô phỏng trọng số đa phân Binary (1-bit) hoặc INT4, kết hợp với các bộ tăng tốc phần cứng NPU (Neural Processing Unit) thế hệ mới trong các dòng vi điều khiển tương lai.

Cả hai giả thuyết trên đều là bước đệm đưa sức mạnh của DSP và AI hội tụ, giải quyết triệt để vấn đề méo âm nhiễu phi tuyến và đáp ứng tiêu chuẩn xử lý cực hạn trên thiết bị thông minh (Smart Wearables).

Tài liệu

- [1] A. Oppenheim and J. Lim, “Evaluation of an adaptive comb filtering method for enhancing speech degraded by white noise addition,” *IEEE Transactions on Acoustics, Speech, and Signal Processing*, vol. 26, no. 4, pp. 353–359, 1978.
- [2] J.-H. Chen and A. Gersho, “Adaptive postfiltering for quality enhancement of coded speech,” *IEEE Transactions on Speech and Audio Processing*, vol. 3, no. 1, pp. 59–71, 1995.
- [3] J.-M. Valin, “A hybrid dsp/deep learning approach to real-time full-band speech enhancement,” in *IEEE 20th International Workshop on Multimedia Signal Processing (MMSP)*. IEEE, 2018, pp. 1–5.
- [4] J.-M. Valin *et al.*, “Noise-robust dsp-assisted neural pitch estimation with very low complexity,” in *ICASSP 2024 - 2024 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*. IEEE, 2024, pp. 11 176–11 180.
- [5] F. Corporation, “Fpt open speech dataset (fosd),” Open-source Dataset, 2021.
- [6] H.-T. Lu and T.-T. Vu, “Vivos: A free vietnamese speech corpus for machine translation and speech recognition,” *Tạp chí khoa học Đại học Khoa học Tự nhiên ĐHQG-HCM*, 2016.
- [7] Thivux, “thivux/phoaudiobook,” Hugging Face Datasets, 2023, high-quality Vietnamese audiobook dataset for clean speech.
- [8] C. K. Reddy *et al.*, “The icassp 2020 deep noise suppression (dns) challenge: Datasets, subjective test framework, and mlt results,” in *ICASSP 2020 - 2020 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*. IEEE, 2020, pp. 8923–8927.
- [9] *ESP32-S3 Technical Reference Manual*, Espressif Systems, 2023. [Online]. Available: https://www.espressif.com/sites/default/files/documentation/esp32-s3_technical_reference_manual_en.pdf